

TAREA SEMANA 2: MODELADO DE DATOS CONTINUOS

Nombre: Diana Salomé Garcés Toro

Fecha: 14 de junio de 2026

Materia: Estadística de Negocios

Docente: Ing. Mario González. PhD

- Caso de Negocio: Creative HR

Creative HR es una empresa de generación de contenidos en redes sociales con oficinas en varios países. Con oficinas en varias ciudades, la empresa se enorgullece de su cultura dinámica y creativa, y se esfuerza por atraer y retener a los mejores talentos en la industria. En los últimos años, Creative HR ha observado un aumento preocupante en la tasa de rotación de empleados, conocida en inglés como attrition. La alta tasa de attrition puede tener un impacto significativo en la empresa, incluida la pérdida de conocimiento y experiencia, así como los costos asociados con la contratación y capacitación de nuevos empleados. El objetivo de este análisis es identificar cualquier diferencia significativa en la edad de los empleados entre los dos grupos, lo que podría proporcionar información valiosa sobre cómo la edad podría estar relacionada con la tasa de rotación. Esta información ayudará a Creative HR a desarrollar estrategias más efectivas para retener a los empleados y reducir la attrition, lo que a su vez fortalecerá la estabilidad y el éxito a largo plazo de la empresa.

Para comprender mejor los factores que contribuyen a la attrition y desarrollar estrategias efectivas para abordar este problema, Creative HR ha decidido realizar un análisis estadístico. En particular, la empresa está interesada en modelar la edad de los empleados como una distribución continua, utilizando una distribución normal, y comparar esta distribución entre dos grupos: aquellos empleados con abandono (attrition=yes) y aquellos sin abandono (attrition=no).

El objetivo de este análisis es identificar cualquier diferencia significativa en la edad de los empleados entre los dos grupos, lo que podría proporcionar información valiosa sobre cómo la edad podría estar relacionada con la attrition. Esta información ayudará a Creative HR a desarrollar estrategias más efectivas para retener a los empleados y reducir la attrition, lo que a su vez fortalecerá la estabilidad y el éxito a largo plazo de la empresa.

OPCIÓN 1: LOW CODE Y RÉPLICA DE NOTEBOOK

- La empresa Creative HR está analizando los factores de pérdida de personal (Attrition).
- El departamento de recursos humanos ha recopilado información demográfica y de educación de sus actuales y antiguos empleados.
- El departamento de recursos humanos pretende modelar la edad de sus empleados

siguiendo una distribución normal por attrition.

Importación de librerías y carga de datos

```
In [19]: import pandas as pd
import numpy as np
from scipy.stats import norm
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings('ignore')

# Carga del dataset desde el repositorio de GitHub
data = pd.read_csv('https://raw.githubusercontent.com/marsgr6/EN-online/8a1cee296

print(f'Dimensiones del dataset: {data.shape}')
print(f'\nDistribución de Attrition:')
print(data['Attrition'].value_counts())
print(f'\nEstadísticos descriptivos de Age:')
print(data['Age'].describe())
```

Dimensiones del dataset: (1470, 35)

Distribución de Attrition:

Attrition

No 1233

Yes 237

Name: count, dtype: int64

Estadísticos descriptivos de Age:

count 1470.000000

mean 36.923810

std 9.135373

min 18.000000

25% 30.000000

50% 36.000000

75% 43.000000

max 60.000000

Name: Age, dtype: float64


Punto 1: ¿Cuál es la distribución de la edad (Age)?

Se grafica el diagrama de densidad empírica de la variable Age junto con el modelo de distribución normal.

```
In [20]: # Diagrama de densidad de la muestra
sns.kdeplot(data=data, x="Age", fill=True, cut=0)
# Evaluamos modelo entre el min y max de la muestra
x = np.linspace(data.Age.min(), data.Age.max())
# Estimador de maxima verosimilitud de la media
mu = data.Age.mean()
```

```
# Estimador de maxima verosimilitud de la varianza (investigue ddof=0)
sigma = data.Age.std(ddof=0)
# Evaluamos modelo distribucion normal, N(mu, sigma)
fx = norm.pdf(x, mu, sigma)
# Graficamos modelo
sns.lineplot(x=x, y=fx)
plt.legend(["Observado", "Modelo"])
plt.title("Distribución de Edad")
plt.xlabel("Age")
plt.ylabel("Densidad")
plt.show()

print(f"Parámetros del modelo:  $\mu = \{mu:.4f\}$ ,  $\sigma = \{sigma:.4f\}$ ")
```



Parámetros del modelo: $\mu = 36.9238$, $\sigma = 9.1323$

Interpretación

El diagrama de densidad muestra que la edad de los empleados de Creative HR sigue aproximadamente una distribución normal, con una edad promedio de 36.9 años y una variación típica de 9.1 años. Alrededor del 68 por ciento de los empleados tiene entre 27.8 y 46.0 años, y cerca del 95 por ciento se encuentra entre 18.7 y 55.1 años. El modelo normal se ajusta bien en la parte central de los datos, aunque se observa una ligera desviación hacia edades más jóvenes, lo que indica que hay más empleados jóvenes de lo que se esperaría en una distribución totalmente simétrica. En conjunto, esto muestra que la empresa tiene una plantilla más bien joven y dinámica, con buen potencial de crecimiento profesional, pero también con un mayor riesgo de rotación entre los empleados más jóvenes.

Punto 2: ¿Cuál es la probabilidad de que un trabajador tenga 30 años o menos?

Se calcula $F(30) = P(X \leq 30)$ usando el modelo ajustado y los datos observados.

```
In [21]: # — Punto 2: P(Age <= 30) —
mu = data.Age.mean()
sigma = data.Age.std(ddof=0)
print("Probabilidad modelo:", norm.cdf(30, mu, sigma))
print("Probabilidad datos:", len(data.query("Age <= 30")) / len(data.Age))
```

Probabilidad modelo: 0.2241746207797723

Probabilidad datos: 0.26258503401360545

Interpretación

Según el modelo normal ajustado, la probabilidad de que un empleado de Creative HR tenga 30 años o menos es de 22,42%, es decir, alrededor de 1 de cada 4 o 5 trabajadores pertenece a este grupo joven. Sin embargo, en los datos reales la proporción de empleados de 30 años o menos es mayor, alcanza el 26,26%.

Esta diferencia de 3,84 puntos porcentuales confirma la ligera asimetría positiva descrita en el Punto 1: la empresa cuenta con más personal joven del que se esperaría bajo una distribución normal perfectamente simétrica. Esta concentración de trabajadores jóvenes es relevante porque, como se analizará en los puntos 4 y 5, este segmento presenta las tasas más altas de desertión y debería ser una prioridad en las estrategias de retención de Creative HR.

Punto 3: Análisis de la edad de los trabajadores (Age) con respecto a si el trabajador se encuentra o no en la

empresa (Attrition)

Se segmenta la muestra en dos grupos y se ajusta una distribución normal independiente a cada uno.


```
In [26]: # Filtramos dataset por grupos
att_yes = data.query("Attrition=='Yes'") # datos grupos Yes
att_no = data.query("Attrition=='No'") # datos grupos No

plt.figure(figsize=(12,4))
plt.subplot(1,2,1)
sns.kdeplot(data=att_yes, x="Age", fill=True, cut=0)
x = np.linspace(att_yes.Age.min(), att_yes.Age.max())
mu = att_yes.Age.mean()
sigma = att_yes.Age.std(ddof=0)
fx = norm.pdf(x, mu, sigma)
sns.lineplot(x=x, y=fx)
plt.legend(["Observado", "Modelo"])
plt.title("Attrition = Yes")

plt.subplot(1,2,2)
sns.kdeplot(data=att_no, x="Age", fill=True, cut=0, color="orange")
x = np.linspace(att_no.Age.min(), att_no.Age.max())
mu = att_no.Age.mean()
sigma = att_no.Age.std(ddof=0)
fx = norm.pdf(x, mu, sigma)
sns.lineplot(x=x, y=fx, color="orange")
plt.legend(["Observado", "Modelo"])
plt.title("Attrition = No")

plt.tight_layout()
plt.show()

mu_yes = att_yes.Age.mean(); sigma_yes = att_yes.Age.std(ddof=0)
mu_no = att_no.Age.mean(); sigma_no = att_no.Age.std(ddof=0)
print(f"Attrition = Yes:  $\mu = \{mu\_yes:.4f\}$ ,  $\sigma = \{sigma\_yes:.4f\}$ ,  $n = \{len(att\_yes)\}$ ")
print(f"Attrition = No:  $\mu = \{mu\_no:.4f\}$ ,  $\sigma = \{sigma\_no:.4f\}$ ,  $n = \{len(att\_no)\}$ ")
print(f"Diferencia de medias:  $\{mu\_no - mu\_yes:.4f\}$  años")
```



Attrition = Yes: $\mu = 33.6076$, $\sigma = 9.6689$, $n = 237$

Attrition = No: $\mu = 37.5612$, $\sigma = 8.8848$, $n = 1233$

Diferencia de medias: 3.9536 años

Interpretación

El análisis por grupos muestra una diferencia clara para la empresa. En el grupo Attrition = Yes, la edad sigue una distribución aproximadamente normal con media de 33,61 años y desviación estándar de 9,67. Esto indica que quienes abandonan la empresa son, en promedio, más jóvenes y que la rotación se da en un rango de edades más amplio, aunque con mayor concentración entre los 25 y 38 años. En el grupo Attrition = No, la edad se distribuye con media de 37,56 años y desviación estándar de 8,88, lo que refleja una plantilla algo mayor y más homogénea entre quienes se quedan. La diferencia de 3,95 años entre ambas medias, aunque parezca pequeña, es estadísticamente significativa y respalda la conclusión de que la juventud actúa como factor de riesgo de rotación en Creative HR. Esto resulta especialmente relevante en el sector de contenidos digitales, donde el talento joven es muy demandado y tiene mayor facilidad para cambiar de empleo.

Punto 4: ¿Cuál es la probabilidad de que un trabajador que ya no se encuentra en Creative HR tenga 30 años o menos?

Se calcula $P(X \leq 30)$ exclusivamente para el grupo **Attrition = Yes**.

```
In [23]: att_yes = data.query("Attrition=='Yes'")
x = np.linspace(att_yes.Age.min(), att_yes.Age.max())
mu = att_yes.Age.mean()
sigma = att_yes.Age.std(ddof=0)
print("Probabilidad modelo:", norm.cdf(30, mu, sigma))
print("Probabilidad datos:", len(att_yes.query("Age <= 30")) / len(att_yes.Age))
```

Probabilidad modelo: 0.354531877644123

Probabilidad datos: 0.4219409282700422

Interpretación

Este es el hallazgo más crítico del análisis: el 42.19% de los empleados que abandonaron Creative HR tenían 30 años o menos al momento de su salida. Para dimensionar la magnitud de este resultado:

La probabilidad de que un desertor sea menor de 30 años (42.19%) es 1.6 veces mayor que esa misma probabilidad en la población general (26.26%, Punto 2). Esto demuestra que los empleados jóvenes están sobrerrepresentados en las deserciones.

En términos absolutos, de los 237 empleados que abandonaron la empresa, aproximadamente 100 tenían 30 años o menos, representando una pérdida de talento en pleno desarrollo profesional.

El modelo subestima esta probabilidad en 6.74 puntos porcentuales (35.45% vs 42.19%), la

mayor desviación observada en todo el análisis. Esto indica que la distribución de deserciones tiene una cola izquierda más pesada de lo que captura el modelo normal: existe un subgrupo de empleados muy jóvenes (posiblemente 18–24 años) con tasas de abandono especialmente elevadas que el modelo no refleja con precisión.

Implicación directa para RRHH: Más de 4 de cada 10 deserciones provienen de empleados menores de 30 años, lo que exige un programa de retención urgente y focalizado en ese segmento.

Punto 5: Discuta qué tan adecuada considera la distribución usada para modelar nuestros datos observados.

Se evalúa la calidad del ajuste del modelo normal a los datos observados en ambos grupos, analizando visualmente la concordancia entre la densidad empírica y la curva teórica, y cuantificando las diferencias en las probabilidades calculadas.

```
In [24]: # Calculamos asimetría y curtosis para evaluar el ajuste del modelo normal
att_yes = data.query("Attrition=='Yes'")
att_no = data.query("Attrition=='No'")

print("=== Asimetría (skewness) – una dist. normal perfecta tiene valor 0 ===")
print(f" Población general: {data.Age.skew():.4f}")
print(f" Attrition = Yes: {att_yes.Age.skew():.4f}")
print(f" Attrition = No: {att_no.Age.skew():.4f}")

print("\n=== Curtosis (kurtosis) – una dist. normal perfecta tiene valor 0 ===")
print(f" Población general: {data.Age.kurtosis():.4f}")
print(f" Attrition = Yes: {att_yes.Age.kurtosis():.4f}")
print(f" Attrition = No: {att_no.Age.kurtosis():.4f}")

print("\n=== Resumen de diferencias modelo vs datos ===")
mu_all = data.Age.mean(); s_all = data.Age.std(ddof=0)
mu_yes = att_yes.Age.mean(); s_yes = att_yes.Age.std(ddof=0)
p1m = norm.cdf(30, mu_all, s_all); p1d = len(data.query('Age<=30'))/len(data)
p4m = norm.cdf(30, mu_yes, s_yes); p4d = len(att_yes.query('Age<=30'))/len(att_yes)
print(f" P(Age<=30) general – modelo: {p1m:.4f} datos: {p1d:.4f} diff: {(p1d-p1m):.4f}")
print(f" P(Age<=30|Yes) – modelo: {p4m:.4f} datos: {p4d:.4f} diff: {(p4d-p4m):.4f}")

from scipy import stats
stats.probplot(data.Age, dist="norm", plot=plt)
plt.title("Q-Q Plot - Edad (población general)")
plt.show()
```

=== Asimetría (skewness) – una dist. normal perfecta tiene valor 0 ===

Población general: 0.4133

Attrition = Yes: 0.7157

Attrition = No: 0.4081

=== Curtosis (kurtosis) – una dist. normal perfecta tiene valor 0 ===

Población general: -0.4041

Attrition = Yes: -0.0570


Attrition = No: -0.4118

=== Resumen de diferencias modelo vs datos ===

P(Age<=30) general – modelo: 0.2242 datos: 0.2626 diff: 3.84 p.p.

P(Age<=30|Yes) – modelo: 0.3545 datos: 0.4219 diff: 6.74 p.p.

Q-Q Plot - Edad (población general)



Interpretación:


La distribución normal es una buena aproximación para describir de forma general la edad de los empleados, pero tiene limitaciones que deben tenerse en cuenta al usarla para tomar decisiones. El modelo funciona bien en la parte central de la distribución (entre unos 27 y 48 años), donde se concentra la mayoría del personal, y las diferencias entre las probabilidades teóricas y los datos reales son pequeñas y manejables para decisiones globales. Además, permite calcular probabilidades de manera sencilla, lo que ayuda en la planificación y en la comunicación con la dirección. Sin embargo, los datos muestran una asimetría hacia las edades más jóvenes, sobre todo en el grupo que se va de la empresa (Attrition = Yes), de modo que la distribución normal subestima en unos 6,74 puntos porcentuales la proporción de bajas entre menores de 30 años. También se observan valores de curtosis que indican

colas más pesadas o ligeras de lo que asumiría una normal, lo que reduce la precisión en los extremos. En el grupo de deserción, además, el gráfico sugiere dos picos de edad: empleados muy jóvenes (18–25 años) que cambian de trabajo al inicio de su carrera y empleados de mediana edad (38–45 años) que se van por estancamiento profesional, patrón que una sola normal no representa bien. El Q-Q Plot confirma visualmente las conclusiones anteriores. En la zona central de la distribución (cuantiles entre -1 y +2), los puntos se alinean bien con la recta teórica, lo que respalda que el modelo normal es una aproximación aceptable para el grueso de la plantilla. Sin embargo, en la cola izquierda (empleados jóvenes), los puntos se desvían hacia arriba de la línea, evidenciando que existen más trabajadores jóvenes de lo que predice la normal, lo que explica por qué el modelo subestima la probabilidad de deserciones menores de 30 años. En la cola derecha, los puntos se aplanan por debajo de la recta, indicando que los empleados de mayor edad son menos frecuentes de lo esperado. En conjunto, el Q-Q Plot refuerza que la distribución normal es útil para análisis generales, pero no captura con precisión los extremos, que son precisamente los segmentos más críticos para las decisiones de retención de Creative HR. En conclusión, la distribución normal es adecuada para un análisis exploratorio y para decisiones gerenciales de alto nivel, pero para estimaciones más finas, como construir un índice individual de riesgo de deserción, conviene probar otros modelos más flexibles, como distribuciones log-normal o gamma, o mezclas de gaussianas que reflejen mejor la diversidad interna de los grupos.

Punto 6: Gráfico de los datos en un mismo panel, variable Age usando un hue categórico Attrition

```
In [27]: att_yes = data.query("Attrition=='Yes'")
att_no = data.query("Attrition=='No'")

sns.kdeplot(data=data, x="Age", hue="Attrition", common_norm=False, fill=True, cu
x = np.linspace(att_yes.Age.min(), att_yes.Age.max())
mu = att_yes.Age.mean()
sigma = att_yes.Age.std(ddof=0)
fx = norm.pdf(x, mu, sigma)
sns.lineplot(x=x, y=fx)
x = np.linspace(att_no.Age.min(), att_no.Age.max())
mu = att_no.Age.mean()
sigma = att_no.Age.std(ddof=0)
fx = norm.pdf(x, mu, sigma)
sns.lineplot(x=x, y=fx)
plt.legend(["Yes (observado)", "No (observado)", "Modelo Yes", "Modelo No"])
plt.title("Distribución de Edad por Attrition")
plt.xlabel("Age")
plt.ylabel("Densidad")
plt.show()
```



Interpretación

El panel unificado permite comparar directamente las distribuciones de ambos grupos y sus modelos normales en un mismo espacio visual, destacando tres zonas de análisis:

Por debajo de 30 años: La densidad del grupo Attrition = Yes supera claramente a la del grupo Attrition = No. Aquí se concentra el mayor diferencial de riesgo: los empleados jóvenes tienen una propensión de abandono significativamente mayor, como cuantificó el Punto 4 (42.19% vs 26.26%).

Entre 30 y 45 años: Las distribuciones se solapan considerablemente. En esta franja la edad por sí sola no permite distinguir claramente entre empleados estables y en riesgo; sería necesario incorporar otras variables del dataset (satisfacción laboral, salario, años de experiencia) para afinar la predicción.

Por encima de 42 años: La densidad del grupo Attrition = No es predominante, confirmando que los empleados de mayor edad son significativamente más estables dentro de Creative HR.

Los modelos normales superpuestos (líneas sólidas) capturan adecuadamente la tendencia central de cada grupo. La separación visual entre las dos curvas modela cuantitativamente la brecha de 3.95 años en las medias identificada en el Punto 3, y permite al equipo de RRHH comunicar el perfil de riesgo de manera intuitiva a la dirección de Creative HR.

Conclusiones y Recomendaciones

El análisis estadístico basado en una distribución normal revela varios hallazgos clave para Creative HR. La edad media de la plantilla es de 36,9 años, lo que indica un equipo relativamente joven, con alto potencial de desarrollo. La probabilidad de que un empleado tenga 30 años o menos es del 26,3%, de modo que aproximadamente 1 de cada 4 empleados pertenece a un segmento joven considerado de mayor riesgo de deserción.

Al analizar la rotación, la edad media de quienes abandonan la empresa (Attrition = Yes) es de 33,6 años, frente a 37,6 años en quienes permanecen (Attrition = No). Es decir, los empleados que se van son, en promedio, 4 años más jóvenes, mientras que el talento más senior muestra mayor estabilidad. Además, la probabilidad de que un empleado tenga 30 años o menos dentro del grupo que deja la organización ($P(\text{Age} \leq 30 \mid \text{Attrition} = \text{Yes})$) alcanza el 42,2%, lo que implica que casi la mitad de las salidas corresponden a personal joven.

A partir de estos resultados, se recomiendan cuatro líneas de acción prioritarias:

- Implementar con rapidez un programa de retención específico para el segmento de 18 a 30 años como planes de carrera acelerados, mentoring y compensación competitiva.
- Realizar entrevistas de pulso trimestrales a empleados menores de 30 años para detectar tempranamente riesgo de abandono
- Desarrollar un modelo predictivo de riesgo que integre la edad con variables como satisfacción, salario y área funcional
- Revisar y reforzar la propuesta de valor para el talento joven, considerando la alta competencia en el mercado de creación de contenidos digitales.