

Tarea Semana 2 - Modelado de datos continuos

(LOW-CODE Y RÉPLICA DE NOTEBOOK)

INTEGRANTES

- 1) OVACO ANDREA
- 2) POZO VIVIANA
- 3) VILLOTA MARTINA

Creative HR

Caso de negocio: **Creative HR** es una empresa de generación de contenidos en redes sociales con oficinas en varios países. Con oficinas en varias ciudades, la empresa se enorgullece de su cultura dinámica y creativa, y se esfuerza por atraer y retener a los mejores talentos en la industria. En los últimos años, Creative HR ha observado un aumento preocupante en la tasa de rotación de empleados, conocida en inglés como *attrition*. La alta tasa de attrition puede tener un impacto significativo en la empresa, incluida la pérdida de conocimiento y experiencia, así como los costos asociados con la contratación y capacitación de nuevos empleados.

Para comprender mejor los factores que contribuyen a la attrition y desarrollar estrategias efectivas para abordar este problema, Creative HR ha decidido realizar un análisis estadístico. **En particular, la empresa está interesada en modelar la edad de los empleados (Age) como una distribución continua, utilizando una distribución normal, y comparar esta distribución entre dos grupos: aquellos empleados con abandono (Attrition = Yes) y aquellos sin abandono (Attrition = No).**

El objetivo de este análisis es identificar cualquier diferencia significativa en la edad de los empleados entre los dos grupos, lo que podría proporcionar información valiosa sobre cómo la edad podría estar relacionada con la attrition. Esta información ayudará a Creative HR a desarrollar estrategias más efectivas para retener a los empleados y reducir la rotación, lo que a su vez fortalecerá la estabilidad y el éxito a largo plazo de la empresa.

El departamento de recursos humanos ha recopilado información demográfica y de educación de sus actuales y antiguos empleados, y pretende modelar la edad de sus empleados siguiendo una distribución normal por attrition.

1. Importar librerías

```
[1]: import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from scipy.stats import norm, shapiro, probplot

sns.set_theme(style="whitegrid")
```

2. Cargar datos

```
[2]: # data = pd.read_csv("https://raw.githubusercontent.com/marsgr6/EN-online/
↳ 8a1cee296279c274d8f05f3905fce97c1f7636a2/data/CHR_data.csv")
data = pd.read_csv("CHR_data.csv")
data.head()
```

```
[2]:
```

	Age	Attrition	BusinessTravel	DailyRate	Department	\
0	41	Yes	Travel_Rarely	1102		Sales
1	49	No	Travel_Frequently	279	Research & Development	
2	37	Yes	Travel_Rarely	1373	Research & Development	
3	33	No	Travel_Frequently	1392	Research & Development	
4	27	No	Travel_Rarely	591	Research & Development	

	DistanceFromHome	Education	EducationField	EmployeeCount	EmployeeNumber	\
0	1	2	Life Sciences	1	1	
1	8	1	Life Sciences	1	2	
2	2	2	Other	1	4	
3	3	4	Life Sciences	1	5	
4	2	1	Medical	1	7	

	RelationshipSatisfaction	StandardHours	StockOptionLevel	\
0	...	1	80	0
1	...	4	80	1
2	...	2	80	0
3	...	3	80	0
4	...	4	80	1

	TotalWorkingYears	TrainingTimesLastYear	WorkLifeBalance	YearsAtCompany	\
0	8	0	1	6	
1	10	3	3	10	
2	7	3	3	0	
3	8	3	3	8	
4	6	3	3	2	

	YearsInCurrentRole	YearsSinceLastPromotion	YearsWithCurrManager
0	4	0	5.0
1	7	1	7.0
2	0	0	0.0
3	7	3	0.0
4	2	2	2.0

[5 rows x 35 columns]

Variables más importantes para el análisis

- **Age:** edad del empleado en años. Es una variable **cuantitativa continua** y es la variable que modelaremos con la distribución normal.

- **Attrition:** indica si el empleado abandonó la empresa. Es una variable **cualitativa (categórica binaria)**: Yes (abandonó) y No (permanece). Es la variable objetivo del negocio.

El dataset incluye además otras variables demográficas y laborales (ingreso, distancia al trabajo, satisfacción, etc.), pero para esta tarea nos centramos en **Age** y **Attrition**.

3. Exploración inicial

```
[3]: data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 373 entries, 0 to 372
Data columns (total 35 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Age                                   373 non-null    int64
1   Attrition                           373 non-null    object
2   BusinessTravel                      373 non-null    object
3   DailyRate                           373 non-null    int64
4   Department                          373 non-null    object
5   DistanceFromHome                    373 non-null    int64
6   Education                           373 non-null    int64
7   EducationField                      373 non-null    object
8   EmployeeCount                       373 non-null    int64
9   EmployeeNumber                      373 non-null    int64
10  EnvironmentSatisfaction              373 non-null    int64
11  Gender                              373 non-null    object
12  HourlyRate                          373 non-null    int64
13  JobInvolvement                      373 non-null    int64
14  JobLevel                            373 non-null    int64
15  JobRole                             373 non-null    object
16  JobSatisfaction                     373 non-null    int64
17  MaritalStatus                       373 non-null    object
18  MonthlyIncome                       373 non-null    int64
19  MonthlyRate                         373 non-null    int64
20  NumCompaniesWorked                  373 non-null    int64
21  Over18                              373 non-null    object
22  OverTime                            373 non-null    object
23  PercentSalaryHike                   373 non-null    int64
24  PerformanceRating                   373 non-null    int64
25  RelationshipSatisfaction             373 non-null    int64
26  StandardHours                       373 non-null    int64
27  StockOptionLevel                    373 non-null    int64
28  TotalWorkingYears                   373 non-null    int64
29  TrainingTimesLastYear               373 non-null    int64
30  WorkLifeBalance                     373 non-null    int64
31  YearsAtCompany                      373 non-null    int64
```

```

32 YearsInCurrentRole      373 non-null    int64
33 YearsSinceLastPromotion  373 non-null    int64
34 YearsWithCurrManager    372 non-null    float64
dtypes: float64(1), int64(25), object(9)
memory usage: 102.1+ KB

```

```
[4]: data.isnull().sum()
```

```

[4]: Age                                0
Attrition                             0
BusinessTravel                        0
DailyRate                            0
Department                           0
DistanceFromHome                     0
Education                             0
EducationField                        0
EmployeeCount                         0
EmployeeNumber                       0
EnvironmentSatisfaction               0
Gender                                0
HourlyRate                            0
JobInvolvement                       0
JobLevel                             0
JobRole                              0
JobSatisfaction                      0
MaritalStatus                        0
MonthlyIncome                        0
MonthlyRate                          0
NumCompaniesWorked                   0
Over18                               0
OverTime                             0
PercentSalaryHike                    0
PerformanceRating                    0
RelationshipSatisfaction              0
StandardHours                        0
StockOptionLevel                     0
TotalWorkingYears                    0
TrainingTimesLastYear                0
WorkLifeBalance                      0
YearsAtCompany                       0
YearsInCurrentRole                   0
YearsSinceLastPromotion              0
YearsWithCurrManager                 1
dtype: int64

```

```

[5]: print("Conteo por Attrition:")
print(data["Attrition"].value_counts())

```

```
print()
print("Resumen estadístico de la Edad (Age):")
data["Age"].describe()
```

Conteo por Attrition:

Attrition

No 316

Yes 57

Name: count, dtype: int64

Resumen estadístico de la Edad (Age):

```
[5]: count    373.000000
     mean     37.064343
     std       9.302338
     min     18.000000
     25%     30.000000
     50%     36.000000
     75%     43.000000
     max     59.000000
     Name: Age, dtype: float64
```

Exploración inicial

Se realizó una inspección del conjunto de datos mediante `info()`, identificando **373 observaciones** y 35 variables. Mediante `isnull().sum()` se comprobó que **no existen valores faltantes** en las variables de interés, lo que garantiza la calidad de los datos para el análisis.

De acuerdo con el conteo de Attrition:

- **316 empleados permanecen** en la empresa (No).
- **57 empleados abandonaron** la empresa (Yes).

Esto implica una **tasa de rotación observada del 15.3 %** (57/373). Existe un claro **desbalance** entre ambos grupos, situación habitual en los problemas de attrition que debe tenerse presente al comparar las distribuciones.

4. Distribución de la edad (Age) — (2 pt)

Replicamos el diagrama de densidad de la variable `Age` y superponemos una distribución normal $X \sim N(\mu, \sigma)$, donde μ es la media y σ la desviación estándar de los datos (`ddof=0`, estimador de máxima verosimilitud).


```
[6]: # Diagrama de densidad de la muestra
sns.kdeplot(data=data, x="Age", fill=True, cut=0)
# Evaluamos el modelo entre el min y max de la muestra
x = np.linspace(data.Age.min(), data.Age.max())
# Estimador de máxima verosimilitud de la media
mu = data.Age.mean()
```

```

# Estimador de máxima verosimilitud de la desviación estándar (ddof=0)
sigma = data.Age.std(ddof=0)
# Modelo distribución normal N(mu, sigma)
fx = norm.pdf(x, mu, sigma)
# Graficamos el modelo
sns.lineplot(x=x, y=fx)
plt.legend(["Muestra", "Modelo"])
plt.title("Edad de los empleados: densidad observada vs. modelo Normal")
plt.xlabel("Age")
plt.show()

print(f"mu (media) = {mu:.4f}")
print(f"sigma (std) = {sigma:.4f}")

```



```

mu (media) = 37.0643
sigma (std) = 9.2899

```

Análisis de la variable Age

La edad de los empleados de Creative HR sigue una distribución **unimodal y aproximadamente acampanada**, por lo que el modelo Normal ajustado se aproxima bien a la forma de los datos

observados.

- La **media** de edad es $\mu \approx 37.06$ años.
- La **desviación estándar** es $\sigma \approx 9.29$ años.
- La mayor concentración de empleados se ubica entre **~28 y ~46 años** (aproximadamente $\mu \pm \sigma$).

Esto evidencia que la fuerza laboral de Creative HR es mayoritariamente adulta-joven a adulta media, sin concentraciones extremas en edades muy bajas o muy altas. Modelar **Age** con una Normal permite responder preguntas probabilísticas (por ejemplo, qué proporción de empleados es menor de cierta edad) sin depender únicamente del conteo de la muestra.

5. Probabilidad de tener 30 años o menos — (2 pt)

Calculamos $P(X \leq 30)$ de dos formas: usando el **modelo** (distribución acumulada $F(30)$) y usando los **datos observados** (frecuencia empírica).

```
[7]: mu = data.Age.mean()
sigma = data.Age.std(ddof=0)
print("Probabilidad modelo:", norm.cdf(30, mu, sigma))
print("Probabilidad datos:", len(data.query("Age <= 30")) / len(data.Age))
```

Probabilidad modelo: 0.2234970202546812

Probabilidad datos: 0.2546916890080429

Análisis: probabilidad de edad 30 años

- Según el **modelo Normal**: $P(X \leq 30) \approx 0.2235$ (22.4 %).
- Según los **datos observados**: ≈ 0.2547 (25.5 %).

Ambas cifras son muy cercanas (diferencia de ~3 puntos), lo que indica que la Normal **captura bien la cola inferior** de la distribución de edades. En términos de negocio: **aproximadamente 1 de cada 4 empleados de Creative HR tiene 30 años o menos**, un segmento joven relevante para diseñar políticas de desarrollo de carrera y retención temprana.

Aclaración: el notebook base muestra valores de referencia (0.2242 / 0.2626) calculados sobre una versión más amplia del dataset HR. Nuestro archivo `CHR_data.csv` contiene 373 registros, por lo que los valores reales son los reportados arriba. El **código y el procedimiento son idénticos**.

6. Edad (Age) según permanencia en la empresa (Attrition) — (2 pt)

Filtramos la muestra en los grupos `Attrition = Yes` y `Attrition = No` y graficamos, para cada uno, su densidad observada junto a su propio modelo Normal.

```
[8]: # Filtramos dataset por grupos
att_yes = data.query("Attrition=='Yes'") # empleados que abandonaron
att_no = data.query("Attrition=='No'") # empleados que permanecen
```


```

plt.figure(figsize=(12,4))
plt.subplot(1,2,1)
sns.kdeplot(data=att_yes, x="Age", fill=True, cut=0)
x = np.linspace(att_yes.Age.min(), att_yes.Age.max())
mu = att_yes.Age.mean()
sigma = att_yes.Age.std(ddof=0)
fx = norm.pdf(x, mu, sigma)
sns.lineplot(x=x, y=fx)
plt.legend(["Muestra", "Modelo"])
plt.title(f"Attrition = Yes (mu={mu:.2f}, sigma={sigma:.2f})")

plt.subplot(1,2,2)
sns.kdeplot(data=att_no, x="Age", fill=True, cut=0, color="orange")
x = np.linspace(att_no.Age.min(), att_no.Age.max())
mu = att_no.Age.mean()
sigma = att_no.Age.std(ddof=0)
fx = norm.pdf(x, mu, sigma)
sns.lineplot(x=x, y=fx, color="orange")
plt.legend(["Muestra", "Modelo"])
plt.title(f"Attrition = No (mu={mu:.2f}, sigma={sigma:.2f})")
plt.show()

print(f"Attrition=Yes -> n={len(att_yes)}, media={att_yes.Age.mean():.2f}, σ={att_yes.Age.std(ddof=0):.2f}")
print(f"Attrition=No -> n={len(att_no)}, media={att_no.Age.mean():.2f}, σ={att_no.Age.std(ddof=0):.2f}")

```



Attrition=Yes -> n=57, media=33.86, sigma=9.39
Attrition=No -> n=316, media=37.64, sigma=9.15

Análisis: edad por Attrition

Los dos grupos presentan distribuciones de edad con forma similar (acampanada), pero **centradas**

en valores distintos:

- **Abandonaron (Yes):** edad media **33.86 años** ($\sigma \approx 9.39$), $n = 57$.
- **Permanecen (No):** edad media **37.64 años** ($\sigma \approx 9.15$), $n = 316$.

La distribución del grupo que abandona está **desplazada hacia la izquierda** (es más joven): su masa de probabilidad se concentra más entre los 20 y los 35 años. Es decir, **los empleados que dejan Creative HR tienden a ser, en promedio, casi 4 años más jóvenes** que quienes permanecen. La rotación se concentra desproporcionadamente en el talento joven, segmento que suele tener mayor movilidad laboral y expectativas de crecimiento rápido.

7. Probabilidad de que un ex-empleado tenga 30 años o menos — (2 pt)

Replicamos el cálculo del punto 5 para el grupo `Attrition = Yes`. Añadimos también el grupo `No` para comparar.

```
[9]: # Grupo que abandonó: Attrition = Yes
att_yes = data.query("Attrition=='Yes'")
mu_y = att_yes.Age.mean()
sigma_y = att_yes.Age.std(ddof=0)
print("== Attrition = Yes ==")
print("Probabilidad modelo:", norm.cdf(30, mu_y, sigma_y))
print("Probabilidad datos:", len(att_yes.query("Age <= 30")) / len(att_yes.Age))

# Para comparar: grupo que permanece, Attrition = No
att_no = data.query("Attrition=='No'")
mu_n = att_no.Age.mean()
sigma_n = att_no.Age.std(ddof=0)
print("\n== Attrition = No ==")
print("Probabilidad modelo:", norm.cdf(30, mu_n, sigma_n))
print("Probabilidad datos:", len(att_no.query("Age <= 30")) / len(att_no.Age))
```

```
== Attrition = Yes ==
Probabilidad modelo: 0.34059816484382044
Probabilidad datos: 0.38596491228070173
```

```
== Attrition = No ==
Probabilidad modelo: 0.20184710839732317
Probabilidad datos: 0.2310126582278481
```

Análisis: probabilidad de edad 30 por grupo

- **Empleados que abandonaron (Yes):** $P(X \leq 30) \approx 0.341$ (modelo) y **0.386** (datos). Es decir, **entre el 34 % y el 39 % de quienes se van tienen 30 años o menos.**
- **Empleados que permanecen (No):** $P(X \leq 30) \approx 0.202$ (modelo) y **0.231** (datos), alrededor del 20–23 %.

La probabilidad de ser menor de 30 años es **claramente mayor en el grupo que abandona**

(~38 %) que en el que permanece (~23 %). Esto **confirma cuantitativamente** el hallazgo del punto 6: el riesgo de rotación es notablemente más alto entre los empleados jóvenes, lo que justifica **focalizar los recursos de retención en el segmento menor de 30 años**.

Nota: igual que en el punto 5, los valores difieren de los de referencia del enunciado (0.3545 / 0.4219) porque estos provienen del dataset HR completo; los nuestros corresponden al archivo CHR_data.csv de 373 registros. El método es el mismo.

8. ¿Qué tan adecuada es la distribución Normal? — (2 pt)


Evaluamos el ajuste con dos herramientas de diagnóstico: el **gráfico Q-Q** (cuantiles observados vs. teóricos) y la **prueba de normalidad de Shapiro-Wilk**.

```
[10]: fig, axes = plt.subplots(1, 2, figsize=(12, 4))

# Q-Q plot de la edad frente a la Normal teórica
probplot(data["Age"], dist="norm", plot=axes[0])
axes[0].set_title("Gráfico Q-Q de Age vs. Normal")

# Histograma + modelo Normal
sns.histplot(data=data, x="Age", stat="density", bins=20, color="lightblue",
             ax=axes[1])
x = np.linspace(data.Age.min(), data.Age.max())
mu = data.Age.mean(); sigma = data.Age.std(ddof=0)
axes[1].plot(x, norm.pdf(x, mu, sigma), color="red", lw=2, label="Modelo Normal")
axes[1].set_title("Histograma de Age vs. modelo Normal")
axes[1].legend()
plt.tight_layout()
plt.show()

W, p_value = shapiro(data["Age"])
print(f"Shapiro-Wilk: W = {W:.4f}, p-value = {p_value:.4f}")
print(f"Coeficiente de asimetría (skew) de Age = {data['Age'].skew():.4f}")
```



Shapiro-Wilk: $W = 0.9704$, $p\text{-value} = 0.0000$
Coeficiente de asimetría (skew) de Age = 0.4592

Análisis: adecuación del modelo Normal

La distribución Normal es una **aproximación razonable pero no perfecta** para la edad de los empleados:

- **A favor del ajuste:** la densidad observada es unimodal y aproximadamente acampanada; en el Q-Q los puntos siguen en gran medida la línea recta en la zona central; y las probabilidades del modelo y de los datos (puntos 5 y 7) son muy cercanas, lo que indica que la Normal reproduce bien las proporciones acumuladas.
- **Limitaciones:** la edad presenta un **leve sesgo positivo** ($\text{skew} = 0.41 > 0$): la cola derecha (edades altas) es algo más larga y en el Q-Q los puntos se desvían en los extremos. Además, la edad es una variable **acotada** (de 18 a 59 años), mientras que la Normal teórica es ilimitada. La prueba de **Shapiro-Wilk** arroja un $p\text{-value}$ pequeño, por lo que en sentido estricto se rechaza la normalidad perfecta —algo esperable en muestras grandes.

Conclusión: para los fines del negocio (estimar proporciones por rango de edad y comparar grupos), el modelo Normal es **suficientemente adecuado y útil**, siempre que se interprete como una aproximación y no se sobre-interpreten las colas extremas.

9. Comparación en un mismo panel: Age con hue = Attrition

Graficamos ambas densidades en un solo panel con `hue="Attrition"` y `common_norm=False` (cada grupo se normaliza por separado para comparar formas). Superponemos los dos modelos Normales.


```
[11]: att_yes = data.query("Attrition=='Yes'")
      att_no  = data.query("Attrition=='No'")

      plt.figure(figsize=(9,5))
      sns.kdeplot(data=data, x="Age", hue="Attrition", common_norm=False, fill=True,
                  cut=0)

      x = np.linspace(att_yes.Age.min(), att_yes.Age.max())
      mu = att_yes.Age.mean(); sigma = att_yes.Age.std(ddof=0)
      sns.lineplot(x=x, y=norm.pdf(x, mu, sigma))

      x = np.linspace(att_no.Age.min(), att_no.Age.max())
      mu = att_no.Age.mean(); sigma = att_no.Age.std(ddof=0)
      sns.lineplot(x=x, y=norm.pdf(x, mu, sigma))

      plt.title("Edad por Attrition (densidades por grupo) + modelos Normales")
      plt.xlabel("Age")
      plt.show()
```



Análisis: comparación conjunta


Al superponer ambas densidades se aprecia con claridad que la **curva de los empleados que abandonan (Yes) está desplazada hacia la izquierda** respecto de la de quienes permanecen (No). El pico del grupo Yes ocurre a una edad menor y su masa entre los ~20 y ~32 años es proporcionalmente mayor. Visualmente, **a menor edad, mayor densidad relativa de abandono**. Esto sintetiza el hallazgo central del análisis: **la edad es un factor diferenciador de la rotación en Creative HR, siendo el personal más joven el de mayor propensión a irse**.

10. Figuras complementarias: Boxplot, Violin y Swarm de Age por Attrition

Estas vistas refuerzan la comparación con estadísticos de posición (mediana, cuartiles), forma de la distribución y observaciones individuales.

```
[12]: fig, axes = plt.subplots(1, 3, figsize=(16, 5))
sns.boxplot(data=data, x="Attrition", y="Age", ax=axes[0])
axes[0].set_title("Boxplot de Age por Attrition")
sns.violinplot(data=data, x="Attrition", y="Age", ax=axes[1])
axes[1].set_title("Violin de Age por Attrition")
sns.swarmplot(data=data, x="Attrition", y="Age", size=3, ax=axes[2])
axes[2].set_title("Swarm de Age por Attrition")
plt.tight_layout()
plt.show()
```

```
print(data.groupby("Attrition")["Age"].describe().round(2))
```



	count	mean	std	min	25%	50%	75%	max
Attrition								
No	316.0	37.64	9.17	18.0	31.0	36.0	43.25	59.0
Yes	57.0	33.86	9.48	18.0	28.0	32.0	39.00	58.0

Análisis de figuras complementarias

- **Boxplot:** la **mediana** del grupo **Yes** (32 años) es menor que la del grupo **No** (36 años), y toda la caja (rango intercuartílico, el 50 % central) del grupo que abandona está desplazada hacia edades más jóvenes. La diferencia no es solo de promedios, sino de toda la posición de la distribución.
- **Violin:** el grupo **Yes** tiene mayor densidad en edades jóvenes, mientras que el grupo **No** es más ancho en el rango 35–45 años.
- **Swarm:** la mayoría de los abandonos individuales se acumulan en el segmento joven, con relativamente pocos casos de empleados mayores que abandonan.

Las tres vistas son consistentes con el modelado Normal y con los cálculos de probabilidad: **la rotación en Creative HR está fuertemente asociada a la juventud del empleado.**

11. Conclusiones y recomendaciones para la gerencia

Hallazgos principales

1. La edad de la plantilla se modela razonablemente bien con una **Normal** $N(37.06, 9.29)$; el ajuste es bueno en el centro de la distribución y aceptable en general, pese a un leve sesgo positivo.
2. **Cerca de 1 de cada 4 empleados (25 %) tiene 30 años o menos.**
3. Los empleados que **abandonan** son, en promedio, **~4 años más jóvenes** (33.9 vs. 37.6 años) y tienen **mayor probabilidad de ser menores de 30** (~38 % vs. ~23 %).
4. Todas las visualizaciones (densidades, boxplot, violin, swarm) apuntan en la misma dirección: **la rotación se concentra en el talento joven.**

Recomendaciones estratégicas

- **Focalizar la retención en menores de 30 años:** planes de carrera claros, mentoría, formación acelerada y revisiones salariales tempranas para el segmento de mayor riesgo.
- **Programas de onboarding y desarrollo** específicos para los primeros años, etapa donde la propensión a irse es mayor.
- **Encuestas de salida segmentadas por edad** para identificar las causas concretas del abandono juvenil (expectativas de crecimiento, compensación, flexibilidad).
- **Monitoreo continuo** de la tasa de attrition por rango de edad para evaluar el impacto de las acciones implementadas.

Advertencia metodológica: el modelo Normal es una aproximación útil para estimar proporciones y comparar grupos, pero no debe usarse para predecir casos individuales ni para sobre-interpretar las colas extremas. Las decisiones deben combinar este análisis con información cualitativa de RR.HH.